Modelos de elección discreta
Notas de clases

Mag. Sadan De la Cruz Almanza

Universidad de Pamplona

Marzo, 2026

Objetivos de aprendizaje

Al finalizar la unidad, el estudiante será capaz de:

- Explicar por qué el MPL es incongruente con el DGP en decisiones binarias.
- Formular el enfoque de variable latente y su regla de observación.
- Derivar y comparar las especificaciones Logit y Probit.
- Identificar problemas de censura/truncamiento y su tratamiento con Tobit.
- Reconocer el rol de la simulación en modelos de alta dimensión.

Motivación

- Muchas decisiones económicas son discretas: empleo, participación, adopción, compra.
- El interés es probabilístico: $P(Y_i = 1|X_i)$.
- La inferencia exige coherencia con el DGP y supuestos claros sobre el término de error.

Agenda

1. Modelo de Probabilidad Lineal (MLP)
2. Modelo Logit
3. Enfoque de Variable Latente
4. Modelo Probit
5. Tobit: Censura y Truncamiento
6. Síntesis y fronteras actuales

Mapa de la sección

1. Modelo de Probabilidad Lineal (MLP)
2. Modelo Logit
3. Enfoque de Variable Latente
4. Modelo Probit
5. Tobit: Censura y Truncamiento
6. Síntesis y fronteras actuales

Fundamentos históricos

El MLP es el modelo más sencillo para los casos en donde una variable dependiente se caracteriza por ser binaria.

- Surge por aplicar MCO a variables binarias por simplicidad.
- Útil para introducir ideas de dependencia condicional y predicción (en el caso de variables dependientes binarias).
- Pero impone restricciones fuertes sobre el DGP.

Definición del MLP

Variable dependiente dicótoma $Y_i \in \{0, 1\}$:

$$P(Y_i = 1|X_i) = E(Y_i|X_i) = X_i\beta$$

- Se fundamenta en la probabilidad condicional.
- $P_i = Y_i = 1$ (*el evento ocurre*)
- $1 - P_i = Y_i = 0$ (*el evento no ocurre*)
- Estimación por MCO.
- Interpretación directa de β como cambio marginal en probabilidad.

Distribución tipo Bernoulli

¿Qué ocurre si Y_i sigue una distribución de probabilidad tipo Bernoulli?.

$$E(Y_i) = 0(1 - P_i) + 1(P_i) = P_i$$

Partiendo del principio de $E(u_i) = 0$ entonces:

$$E(Y_i|X_i) = X_i\beta = P_i$$

Patología 1: No normalidad en u_i

El supuesto de normalidad para u_i no se mantiene en MLP. u_i solo toma dos valores:

$$u_i = Y_i - \beta_0 + \beta_1 X_i$$

Reemplazamos los valores de Y_i en la ecuación:

$$Y_i = 1 = 1 - \beta_0 - \beta_1 X_i = P_i$$

$$Y_i = 0 = -\beta_0 - \beta_1 X_i = 1 - P_i$$

Patología 2: Heterocedasticidad inherente

Si $Y_i \sim$ Bernoulli(P_i):

$$\text{Var}(Y_i|X_i) = P_i(1 - P_i)$$

$$\text{Var}(u_i|X_i) = (X_i\beta)(1 - X_i\beta)$$

- Se viola homocedasticidad.
- MCO deja de ser BLUE.

Patología 3: Probabilidades fuera de rango

- $X_i\beta$ no está acotado en $[0, 1]$.
- $0 < E(Y_i|X_i) < 1$.
- Predicciones negativas o mayores que uno.
- Inconsistencia interpretativa y económica.

Factores criticos

- Predicciones fuera del rango lógico.
- Presencia de heterocedasticidad.
- Distribución no normal de los errores.
- Supuesto de efecto marginal constante.
- Sensibilidad a la variabilidad y distribución de la muestra (*en el caso de pocas observaciones*).

Mapa de la sección

1. Modelo de Probabilidad Lineal (MLP)
2. Modelo Logit
3. Enfoque de Variable Latente
4. Modelo Probit
5. Tobit: Censura y Truncamiento
6. Síntesis y fronteras actuales

Concepto

Se le conoce como logit porque utiliza la función logística para modelar probabilidades siguiendo una curva en forma de **S**.

- La distribución no es lineal y no se puede linealizar.
- No se puede estimar por MCO.
- El método de estimación es por máxima verosimilitud (MV).

El "chance"

Razón de probabilidades (odds):

$$\text{Odds}_i = \frac{P_i}{1 - P_i}$$

$$\ln\left(\frac{P_i}{1 - P_i}\right) = X_i\beta$$

- Interpretación de β en términos de log-odds.

Nota: Si el resultado de $Odds_i = 4$ podemos decir que es "4 veces más probable que ocurra el evento".

Del "chance" al modelo logit (I)

$$
\begin{aligned}
\log\left(\frac{Y}{1-Y}\right) &= X\beta \\
\frac{Y}{1-Y} &= e^{X\beta} \\
Y &= (1-Y)e^{X\beta} \\
Y &= e^{X\beta} - e^{X\beta}Y \\
Y + e^{X\beta}Y &= e^{X\beta} \\
(1+e^{X\beta})Y &= e^{X\beta}
\end{aligned}
$$

Del "chance" al modelo logit (II)

$$
\begin{aligned}
Y &= \frac{e^{X\beta}}{1+e^{X\beta}} \\
F(X\beta) &= \frac{e^{X\beta}}{1+e^{X\beta}} = \frac{1}{1+e^{-X\beta}} \\
P_i &= \frac{1}{1+e^{-(\beta_1+\beta_2 x_{2i}+\cdots+\beta_k x_{ki}+u_i)}}
\end{aligned}
$$

Notas sobre P_i

- Si $X\beta$ tiende a infinito -> $e^{X\beta}$ tiende a 0 y $\frac{1}{1+e^{-X\beta}}$ tiende a uno.
- Si $X\beta$ tiende a menos infinito -> $e^{X\beta}$ tiende a infinito y $\frac{1}{1+e^{-X\beta}}$ tiende a 0.
- Las probabilidades están acotadas por límites factibles.

Mapa de la sección

1. Modelo de Probabilidad Lineal (MLP)
2. Modelo Logit
3. Enfoque de Variable Latente
4. Modelo Probit
5. Tobit: Censura y Truncamiento
6. Síntesis y fronteras actuales

Modelo estructural

$$Y_i^* = X_i\beta + u_i$$

Regla de observación:

$$Y_i = \begin{cases} 1 & \text{si } Y_i^* > 0 \\ 0 & \text{si } Y_i^* \leq 0 \end{cases}$$

Notebook LM: ¿Por qué se le llaman variable latente?

Necesidad de no linealidad

- Se requiere $P(Y_i = 1|X_i) = G(X_i\beta)$ con $G(\cdot)$ acotada.
- $G(\cdot)$ es una FDA.
- La elección de G depende de la distribución de u_i.

Mapa de la sección

1. Modelo de Probabilidad Lineal (MLP)
2. Modelo Logit
3. Enfoque de Variable Latente
4. Modelo Probit
5. Tobit: Censura y Truncamiento
6. Síntesis y fronteras actuales

Supuesto de normalidad

- $u_i \sim N(0,1)$.
- La varianza se fija para identificación.

Función probit

$$P(Y_i = 1|X_i) = \Phi(X_i\beta)$$

- $\Phi(\cdot)$: FDA normal estándar.
- Estimación por MV.

Comparación Logit vs. Probit

- Resultados similares en el centro de la distribución.
- Logit: colas más pesadas.
- Probit multinomial requiere integrales complejas.

Simulación en Probit multinomial

- Integrales multidimensionales complejas.
- Simulador GHK (Geweke–Hajivassiliou–Keane).
- La simulación es crucial para la frontera metodológica.

Mapa de la sección

1. Modelo de Probabilidad Lineal (MLP)
2. Modelo Logit
3. Enfoque de Variable Latente
4. Modelo Probit
5. Tobit: Censura y Truncamiento
6. Síntesis y fronteras actuales

Motivación

- Variables continuas con soluciones de esquina: gasto, horas, consumo.
- Observaciones acumuladas en el límite inferior (censura).

Modelo Tobit estándar

$$Y_i = \max(0, X_i\beta + u_i)$$

- Censura en cero.
- Distinción clave: censura vs. truncamiento.

Censura vs. truncamiento

Censura	**Truncamiento**
Observamos X para toda la muestra	Muestra restringida
Y se acumula en el límite	Observaciones fuera del rango no existen

Sesgo de selección

- MCO sobre $Y_i > 0$ produce sesgo e inconsistencia.
- Correlación entre errores de selección e intensidad.
- Conexión con Heckman (1990).

Mapa de la sección

1. Modelo de Probabilidad Lineal (MLP)
2. Modelo Logit
3. Enfoque de Variable Latente
4. Modelo Probit
5. Tobit: Censura y Truncamiento
6. Síntesis y fronteras actuales

Mapa conceptual

- MPL: linealidad y simplicidad, pero incongruencia con DGP.
- Logit/Probit: coherencia probabilística y MV.
- Tobit: decisiones continuas con censura/truncamiento.

Hacia modelos estructurales

- Programación Dinámica Estructural (Rust, 1987).
- Vínculo entre teoría del agente optimizador e inferencia moderna.

Lecturas recomendadas

- Palgrave Handbook of Econometrics (capítulos de microeconometría).
- McFadden (premio Nobel) y Heckman (premio Nobel).
- Tobin (1950) y desarrollos modernos (Autometrics).

Cierre

- La elección discreta exige modelos no lineales coherentes.
- La simulación es central en extensiones de alta dimensión.
- Próxima unidad: efectos marginales, elasticidades y predicción.